

アルゴリズム第2 期末レポート

61908697 佐々木良輔

問3 最小二乗法の拡張

最小二乗法は測定で得られた離散的なデータを関数で近似するために用いられる。ここでは特に近似を行う関数形が m 次多項式の場合を考える。すなわち関数は

$$g(x) = \sum_{k=0}^m a_k x^k = a_0 + a_1 x + \cdots + a_m x^m \quad (1)$$

という形で表される。ここで n 組の離散データの組が (x_i, y_i) で与えられるとき最小二乗法ではこれらのデータと $g(x)$ の残差の二乗和 E が最小となるように a_k を定める。すなわち目的関数は以下で与えられる。ただし a_0, \dots, a_m を a_k と略記している。

$$\text{minimize : } E(a_k) = \sum_{i=0}^{n-1} (y_i - g(x_i))^2 \quad (2)$$

ここで a_k について $E(a_k)$ が唯一極小値を持つことを仮定すると $E(a_k)$ が最小となる条件は

$$\begin{aligned} \frac{\partial E}{\partial a_k} &= \frac{\partial}{\partial a_k} \sum_{i=0}^{n-1} (y_i - (a_0 + \cdots + a_k x_i^k + \cdots + a_m x_i^m))^2 \\ &= 2 \sum_{i=0}^{n-1} (y_i - g(x_i))(-x_i^k) = 0 \end{aligned} \quad (3)$$

すなわち

$$\sum_{i=0}^{n-1} (a_0 x_i^k + a_1 x_i^{k+1} + \cdots + a_m x_i^{k+m}) = \sum_{i=0}^{n-1} y_i x_i^k \quad (4)$$

となる。 $k = 0, \dots, m$ までを並べて行列とすると

$$\begin{pmatrix} n & \bar{x} & \cdots & \overline{x^m} \\ \bar{x} & \overline{x^2} & \cdots & \overline{x^{m+1}} \\ \vdots & \vdots & \ddots & \vdots \\ \overline{x^m} & \overline{x^{m+1}} & \cdots & \overline{x^{2m}} \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{pmatrix} = \begin{pmatrix} \bar{y} \\ \overline{xy} \\ \vdots \\ \overline{x^m y} \end{pmatrix} \quad (5)$$

ここで $\overline{x^k y}$ などは $\sum_{i=0}^{n-1} x_i^k y_i$ を意味する. 以上から (5) 式の連立方程式を解くことで $E(a_k)$ を最小化する a_k が得られる. また m 次多項式での最小二乗法は係数行列の生成に $O(m^2 \times n)$ の総和計算, 連立方程式を解くのに $O(m^2)$ の計算量が必要と見積もられる.

以上の最小二乗法を数値計算するプログラム (lsm_polynomial.c) を c 言語で実装した. ソースコードをに示す. 入力データは 1 列目に時刻, 2 列目に値を持ったテキストファイルである. また入力ファイルの 1 行 1 列にはデータ数を, 1 行 2 列には多項式の次数を与える. 連立方程式のソルバーとしてガウスの消去法を用いた.

まず動作確認として, 第 10 回授業で配布された xy9.txt と同一のデータを直線回帰し, その結果を同じく第 10 回授業で配布された lsm.c の出力結果と比較した. それぞれのプログラムで得られた回帰直線は以下の通りである. この結果から 2 つの lsm_polynomial.c は lsm.c と全く同一の出力をしており, 正常に動作していると考えられる.

表 1 動作確認の結果

プログラム	回帰直線
lsm.c	$y = 12.068x - 5.011$
lsm_polynomial.c	$y = 12.068x - 5.011$

次に幾つかの次数の多項式から生成されたデータを用いてプログラムの性能を評価した. ここではデータの生成プログラムとして generate_data.c を作成した. これは任意の多項式関数に対して正規分布に従うノイズを乗せたものをファイルに保存するプログラムである. 正規分布に従う乱数は [1] を参考にした. また性能は計算に要した CPU 時間で評価した.

参考文献

- [1] 近江崇宏. C 言語による乱数生成. https://omitakahiro.github.io/random/random_variables_generation.html#Prepare_rand. (Accessed on 07/30/2021).