

# アルゴリズム第2 期末レポート

61908697 佐々木良輔

## 問3 最小二乗法の拡張

最小二乗法は測定で得られた離散的なデータを関数で近似するために用いられる。ここでは特に近似を行う関数形が  $m$  次多項式の場合を考える。すなわち関数は

$$g(x) = \sum_{k=0}^m a_k x^k = a_0 + a_1 x + \cdots + a_m x^m \quad (1)$$

という形で表される。ここで  $n$  組の離散データの組が  $(x_i, y_i)$  で与えられるとき最小二乗法ではこれらのデータと  $g(x)$  の残差の二乗和  $E$  が最小となるように  $a_k$  を定める。すなわち目的関数は以下で与えられる。ただし  $a_0, \dots, a_m$  を  $a_k$  と略記している。

$$\text{minimize : } E(a_k) = \sum_{i=0}^{n-1} (y_i - g(x_i))^2 \quad (2)$$

ここで  $a_k$  について  $E(a_k)$  が唯一極小値を持つことを仮定すると  $E(a_k)$  が最小となる条件は

$$\begin{aligned} \frac{\partial E}{\partial a_k} &= \frac{\partial}{\partial a_k} \sum_{i=0}^{n-1} (y_i - (a_0 + \cdots + a_k x_i^k + \cdots + a_m x_i^m))^2 \\ &= 2 \sum_{i=0}^{n-1} (y_i - g(x_i))(-x_i^k) = 0 \end{aligned} \quad (3)$$

すなわち

$$\sum_{i=0}^{n-1} (a_0 x_i^k + a_1 x_i^{k+1} + \cdots + a_m x_i^{k+m}) = \sum_{i=0}^{n-1} y_i x_i^k \quad (4)$$

となる。  $k = 0, \dots, m$  までを並べて行列とすると

$$\begin{pmatrix} n & \bar{x} & \cdots & \overline{x^m} \\ \bar{x} & \overline{x^2} & \cdots & \overline{x^{m+1}} \\ \vdots & \vdots & \ddots & \vdots \\ \overline{x^m} & \overline{x^{m+1}} & \cdots & \overline{x^{2m}} \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{pmatrix} = \begin{pmatrix} \bar{y} \\ \overline{xy} \\ \vdots \\ \overline{x^m y} \end{pmatrix} \quad (5)$$

ここで  $\overline{x^k y}$  などは  $\sum_{i=0}^{n-1} x_i^k y_i$  を意味する. 以上から (5) 式の連立方程式を解くことで  $E(a_k)$  を最小化する  $a_k$  が得られる. また  $m$  次多項式での最小二乗法は係数行列の生成に  $O(m^2 \times n)$  の総和計算, 連立方程式を解くのに  $O(m^2)$  の計算量が必要と見積もられる.

以上の最小二乗法を数値計算するプログラム (lsm\_polynomial.c) を c 言語で実装した. ソースコードをに示す. 入力データは 1 列目に時刻, 2 列目に値を持ったテキストファイルである. また入力ファイルの 1 行 1 列にはデータ数を, 1 行 2 列には多項式の次数を与える. 連立方程式のソルバーとしてガウスの消去法を用いた.

まず動作確認として, 第 10 回授業で配布された xy9.txt と同一のデータを直線回帰し, その結果を同じく第 10 回授業で配布された lsm.c の出力結果と比較した. それぞれのプログラムで得られた回帰直線は以下の通りである. この結果から 2 つの lsm\_polynomial.c は lsm.c と全く同一の出力をしており, 正常に動作していると考えられる.

表 1 動作確認の結果

プログラム	回帰直線
lsm.c	$y = 12.068x - 5.011$
lsm_polynomial.c	$y = 12.068x - 5.011$